

Conceptos de Estadística Espacial: Datos Vectoriales y Análisis de Formas

Julio Segundo Eduardo Maquera

Curso: Estadística Espacial

Docente: Ing. Torres Cruz Fred

Abstract

La estadística espacial se enfoca en el análisis de datos que presentan dependencia espacial, donde las observaciones están influenciadas por su ubicación geográfica. Este trabajo examina el papel de los modelos de datos vectoriales y el análisis de formas dentro del marco estadístico del análisis espacial. Se pone énfasis en la autocorrelación espacial global y local, los procesos puntuales y los métodos geostatísticos. Las representaciones vectoriales, incluyendo puntos, líneas y polígonos, son analizadas como estructuras fundamentales que permiten modelar relaciones espaciales y dependencia estadística. La integración de enfoques geométricos y estadísticos permite una comprensión más profunda de los fenómenos espaciales.

1. Introducción

La estadística espacial extiende los métodos estadísticos clásicos al incorporar la dependencia espacial y la heterogeneidad. En muchos fenómenos reales, las observaciones no son independientes, lo que contradice uno de los supuestos fundamentales de la estadística tradicional.

Este comportamiento se explica mediante la Primera Ley de Tobler, la cual establece que los elementos cercanos tienden a estar más relacionados que los lejanos. Esta propiedad se conoce como autocorrelación espacial y constituye un concepto central en el análisis de datos espaciales.

Los modelos de datos vectoriales proporcionan una estructura fundamental para representar observaciones espaciales, permitiendo aplicar técnicas estadísticas sobre datos georreferenciados.

2. Datos Vectoriales como Marco Estadístico

2.1. Representación Espacial

En estadística espacial, los datos vectoriales permiten representar observaciones discretas en el espacio:

- **Puntos:** Representan eventos o realizaciones de procesos espaciales.
- **Líneas:** Representan interacciones o flujos espaciales.
- **Polígonos:** Representan unidades espaciales agregadas.

Estas estructuras no solo son geométricas, sino también unidades de análisis estadístico.

2.2. Matriz de Pesos Espaciales y Topología

Un concepto fundamental es la matriz de pesos espaciales W , que representa las relaciones entre observaciones. Esta matriz se construye a partir de la proximidad o la vecindad entre unidades espaciales, donde el elemento w_{ij} toma el valor 1 si las unidades i y j son vecinas (contiguas o están dentro de un umbral de distancia definido) y 0 en caso contrario. La suma total de todos los pesos se denota como:

$$S_0 = \sum_i \sum_j w_{ij}$$

La matriz W es esencial para modelar la dependencia espacial y se utiliza en múltiples estadísticos espaciales.

3. Análisis de Formas en Estadística Espacial

3.1. Interpretación Estadística de la Forma

La forma de los objetos espaciales no solo tiene un significado geométrico, sino también estadístico, ya que puede reflejar procesos subyacentes. El análisis morfológico de unidades espaciales permite caracterizar fenómenos como la fragmentación territorial, la concentración poblacional o la complejidad de bordes administrativos y naturales.

3.2. Medidas Cuantitativas de Forma

Entre las principales métricas se encuentran:

- **Compacidad** (grado de concentración espacial): se mide como la relación entre el área del polígono y el área del círculo que tiene el mismo perímetro. Un índice cercano a 1 indica forma circular compacta.

$$C = \frac{4\pi A}{P^2}$$

donde A es el área y P el perímetro del polígono.

- **Dimensión fractal** (complejidad del borde): cuantifica la irregularidad del contorno de un polígono. Se estima como:

$$D = \frac{2 \ln(P/4)}{\ln(A)}$$

donde valores cercanos a 1 indican formas simples y valores cercanos a 2 indican contornos muy irregulares.

- **Relación perímetro-área** (irregularidad): razón directa entre el perímetro y el área, utilizada como indicador simple de complejidad de forma.

$$R_{PA} = \frac{P}{A}$$

Estas métricas pueden utilizarse como variables explicativas en modelos estadísticos espaciales.

4. Métodos Fundamentales de Estadística Espacial

4.1. Autocorrelación Espacial Global: Índice de Moran

La autocorrelación espacial mide el grado de similitud entre observaciones cercanas. El **Índice de Moran Global** es uno de los estadísticos más utilizados para este fin:

$$I = \frac{n}{S_0} \cdot \frac{\sum_i \sum_j w_{ij} (x_i - \bar{x})(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2}$$

donde:

- n es el número total de observaciones,
- w_{ij} son los elementos de la matriz de pesos espaciales W ,
- $S_0 = \sum_i \sum_j w_{ij}$ es la suma total de todos los pesos,
- x_i y x_j son los valores del atributo en las unidades i y j , respectivamente,

- $\bar{x}$ es la media global del atributo.

Los valores del índice oscilan típicamente entre -1 (dispersión perfecta) y $+1$ (agrupamiento perfecto), siendo 0 indicador de distribución espacial aleatoria.

4.2. Autocorrelación Espacial Local: Indicadores LISA

Además del índice global, Anselin (1995) propuso los **Indicadores Locales de Asociación Espacial (LISA)**, que descomponen la autocorrelación espacial a nivel de cada unidad:

$$I_i = \frac{x_i - \bar{x}}{m_2} \sum_j w_{ij} (x_j - \bar{x})$$

donde $m_2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2$ es la varianza de la variable. Los indicadores LISA permiten identificar clústeres locales (*hot spots* y *cold spots*) que podrían quedar enmascarados en la medida global.

4.3. Procesos Puntuales

El análisis de patrones de puntos considera los datos como realizaciones de procesos estocásticos espaciales. El modelo de referencia es el **Proceso de Poisson Homogéneo** con intensidad constante λ (número esperado de eventos por unidad de área), que representa la hipótesis de *Complete Spatial Randomness* (CSR):

$$P(N(A) = k) = \frac{(\lambda|A|)^k e^{-\lambda|A|}}{k!}$$

donde $N(A)$ es el número de eventos en la región A y $|A|$ su área. Bajo CSR, la presencia de un evento en cualquier punto no influye en la probabilidad de ocurrencia en otro punto. Las desviaciones respecto a este modelo permiten detectar agrupamiento o inhibición espacial.

4.4. Geoestadística

La geoestadística se enfoca en variables continuas distribuidas en el espacio. El **variograma** (o semivariograma) describe la estructura de dependencia espacial:

$$\gamma(h) = \frac{1}{2} \mathbb{E} [(Z(\mathbf{x}) - Z(\mathbf{x} + \mathbf{h}))^2]$$

donde $Z(\mathbf{x})$ es el valor de la variable en la ubicación $\mathbf{x}$ y $\mathbf{h}$ es el vector de distancia (rezago). En la práctica, el variograma experimental se estima como:

$$\hat{\gamma}(h) = \frac{1}{2n(h)} \sum_{i=1}^{n(h)} [Z(\mathbf{x}_i) - Z(\mathbf{x}_i + \mathbf{h})]^2$$

donde $n(h)$ es el número de pares de puntos separados por la distancia h . Las principales características del variograma son: la **pepita** (*nugget*), el **umbral** (*sill*) y el **alcance** (*range*).

Este modelo es fundamental para técnicas de interpolación como el **kriging**, que produce estimaciones lineales insesgadas de mínima varianza en ubicaciones no muestreadas.

5. Integración entre Geometría y Estadística

La geometría vectorial define la estructura de los datos espaciales, mientras que los métodos estadísticos permiten modelar su dependencia y variabilidad. La integración de ambos enfoques es clave para el análisis espacial moderno. Las métricas de forma derivadas de los datos vectoriales pueden incorporarse directamente como covariables en modelos de regresión espacial, enriqueciendo la capacidad explicativa de los análisis.

6. Desafíos y Tendencias Futuras

Entre los principales desafíos se encuentran:

- Modelar la heterogeneidad espacial no estacionaria.
- Manejar grandes volúmenes de datos espaciales (*big spatial data*).
- Integrar técnicas de inteligencia artificial y aprendizaje automático con métodos geoestadísticos clásicos.

Las tendencias actuales incluyen el análisis de *big data* espacial, la analítica en tiempo real y el desarrollo de métodos de kriging no estacionario y kriging con aprendizaje profundo.

7. Conclusiones

La estadística espacial proporciona herramientas fundamentales para el análisis de datos geográficos. Los datos vectoriales y el análisis de formas permiten representar y estudiar estructuras espaciales de manera precisa. La combinación de geometría y estadística fortalece la capacidad de modelar fenómenos complejos en el espacio. La distinción entre medidas globales (Índice de Moran) y locales (LISA) enriquece el análisis al revelar tanto patrones generales como heterogeneidades locales. Asimismo, la correcta definición del variograma y sus parámetros constituye la base indispensable para aplicaciones de interpolación mediante kriging.

References

- [1] P. Chen y W. Shi, “Measuring the spatial relationship information of multi-layered vector data,” *ISPRS International Journal of Geo-Information*, 2018. DOI: <https://doi.org/10.3390/ijgi7030088>
- [2] L. Anselin, “Local indicators of spatial association—LISA,” *Geographical Analysis*, vol. 27, no. 2, pp. 93–115, 1995. DOI: <https://doi.org/10.1111/j.1538-4632.1995.tb00338.x>
- [3] X. Yao y G. Li, “Big spatial vector data management: a review,” *Big Earth Data*, 2018. DOI: <https://doi.org/10.1080/20964471.2018.1432115>
- [4] J. Illian, A. Penttinen, H. Stoyan y D. Stoyan, *Statistical Analysis and Modelling of Spatial Point Patterns*, Wiley, 2008. DOI: <https://doi.org/10.1002/9780470725160>
- [5] M. Batty, “The size, scale, and shape of cities,” *Science*, vol. 319, pp. 769–771, 2008. DOI: <https://doi.org/10.1126/science.1151419>
- [6] N. Cressie, *Statistics for Spatial Data*, revised ed., Wiley, 1993.
- [7] P. A. P. Moran, “Notes on continuous stochastic phenomena,” *Biometrika*, vol. 37, no. 1/2, pp. 17–23, 1950.